

Основы Python

Урок 6. Работа с файлами



На этом уроке

1. Будем читать и сохранять файлы. Вспомним про генераторы.
2. Познакомимся с менеджерами контекста.
3. Поговорим о сериализации

Оглавление

[Читаем текстовый файл целиком](#)

[Чтение файлов: тонкости](#)

[Запись файлов](#)

[Изменение файлов: добавление и перезапись контента](#)

[* Перемещение курсора при работе с файлом: `.seek\(\)` и `.tell\(\)`](#)

[Сериализация данных](#)

[Сериализация при помощи модуля `json`](#)

[Работа с бинарными файлами. Модуль `pickle`](#)

[Практическое задание](#)

[Дополнительные материалы](#)

[Используемая литература](#)

Читаем текстовый файл целиком

Создадим в папке с уроком текстовый файл:

hello.txt

```
Привет всем, добравшимся до 6-го урока.  
Работаем с файлами.
```

Обязательно сохраняем его в кодировке UTF-8. Можно создать его прямо в PyCharm.

Самый простой способ прочитать содержимое файла в Python:

```
file_1 = open('hello.txt', 'r', encoding='utf-8')  
content = file_1.read()  
print(content)  
file_1.close()  
# Привет всем, добравшимся до 6-го урока.  
# Работаем с файлами.
```

Разберем шаги подробнее. Для доступа к файлам в Python используется функция [open\(\)](#). Её первый аргумент — путь к файлу. Он может быть относительным, как в нашем случае, и абсолютным. Второй позиционный аргумент — режим доступа к файлу:

- `'r'` — режим чтения (значение по умолчанию);
- `'r+'` — режим редактирования, указатель (курсор) устанавливается на начало файла, данные пишутся поверх существующих. Если файла нет, генерируется исключение [FileNotFoundError](#);
- `'w'` — режим записи, существующий файл стирается (весь его контент исчезнет);
- `'w+'` — режим записи и чтения, существующий файл стирается (весь его контент исчезнет), после записи данных можно их читать (в режиме `'w'` можно только писать);
- `'x'` — режим записи для случая, когда файла нет. Если файл существует, генерируется исключение [FileExistsError](#) и никаких действий с ним не будет;
- `'a'` — режим дозаписи, указатель (курсор) устанавливается в конец файла, если файла нет — создается новый;
- `'a+'` — режим дозаписи и чтения, похож на режим `'a'`, но кроме записи можно читать данные;
- `'t'` — текстовый режим (значение по умолчанию);

- `'b'` — бинарный режим (работа с исполняемыми файлами, медиафайлами, с дампами).

Следующий аргумент — именованный: кодировка файла. Для бинарных файлов он не имеет смысла. Рекомендуем всегда явно задавать кодировку, чтобы не было проблем с русскими буквами. Если этого не делать, скрипт, который нормально работал в Windows, потом может некорректно работать в Linux. Было бы хорошо вызвать для переменной `file_1` функцию `dir()`, посмотреть методы и атрибуты [файлового объекта](#), который она создаёт. Важно понять, что это не сам файл, а его «представитель», «дилер» в нашей программе. Мы ещё не читали файл в момент создания файлового объекта. Для чтения содержимого есть несколько разных способов. Один из них — вызов метода `.read()`. **Важно**, что при этом читается **всё** содержимое файла. А если размер файла превышает размер оперативной памяти? Этот случай мы рассмотрим позже. На практике он может встречаться достаточно часто: файлы логов бывают очень большими.

Итак, прочитали файл. Можно на этом и завершить скрипт. Но это было бы ошибкой. Причем **очень** серьезной. Дело в том, что файл — это ресурс, к которому может понадобиться доступ не только нашей программе, но и другим процессам, выполняющимся в операционной системе. Во время вызова функции `open()` мы этот ресурс «заняли» — теперь нужно «освободить»: вызываем метод `.close()` файлового объекта. Многие начинающие программисты недооценивают важность этой манипуляции, потому что на первых порах «ничего страшного» не происходит. Будьте внимательны.

Вы задумались: почему текст при выводе на экран выглядит точно так же, как в нашем файле? Дело в том, что метод `.read()` читает «сырой» текст вместе с [управляющими символами](#) `"\n"`, `"\r"` и другими. Коварство этих символов в том, что они невидимы как символы — просто происходит перенос строки, например. В некоторых алгоритмах мы заменяем эти символы пробелами:

```
...
clean_content = content.replace('\n', ' ').replace('\r', ' ')
print(clean_content)
# Привет всем, добравшимся до 6-го урока. Работаем с файлами.
```

В других алгоритмах превращаем текст в список, состоящий из абзацев, при помощи метода [.splitlines\(\)](#):

```
...
paragraphs = content.splitlines()
print(paragraphs)
# ['Привет всем, добравшимся до 6-го урока.', 'Работаем с файлами.']
```

Причём можно получить такой список сразу, вызвав метод `.readlines()` файлового объекта:

```
file_1 = open('hello.txt', 'r', encoding='utf-8')
paragraphs = file_1.readlines()
print(paragraphs)
file_1.close()
```

```
# ['Привет всем, добравшимся до 6-го урока.\n', 'Работаем с файлами.']
```

Особенность: управляющие символы при этом тоже будут прочитаны — Python читает «сырые» строки. Можно потом через `map()` или другим способом удалить эти символы. На наш взгляд, предыдущий пример выглядит более логичным для получения списка абзацев из текста.

Чтение файлов: тонкости

А что, если в алгоритме можно ограничиться чтением файла по строкам? При этом можем получить серьёзный выигрыш по памяти. НО, ВОЗМОЖНО, И ПРОИГРЫШ ПО ПРОИЗВОДИТЕЛЬНОСТИ скрипта в целом: каждая операция доступа к файлу занимает **очень много** времени по сравнению с чтением информации из оперативной памяти. С появлением SSD-накопителей скорость работы с диском повысилась, но она все равно намного ниже скорости работы с памятью. Поэтому при реализации чтения файла по строкам или другим порциям нужно четко понимать плюсы и минусы такого решения.

При работе с текстовыми файлами можем использовать метод `.readline()` файлового объекта для чтения одной строки:

```
file_1 = open('hello.txt', 'r', encoding='utf-8')
print(file_1.readline())
print(file_1.readline())
file_1.close()
# Привет всем, добравшимся до 6-го урока.
#
# Работаем с файлами.
```

Вы заметили «лишнюю» строку? Опять имеем дело с чтением «сырой» строки с управляющими символами. А что, если ещё раз вызвать метод `.readline()`? Получим либо содержимое очередной строки, либо пустую строку, если строк в файле больше нет. Таким образом можно организовать цикл построчного чтения файла:

```
file_1 = open('hello.txt', 'r', encoding='utf-8')
line = file_1.readline()
while line:
    print(line)
    line = file_1.readline()
file_1.close()
```

Мы уже знаем, что в Python подобные манипуляции лучше делать через цикл-итератор, поэтому предпочтительнее следующий код:

```
file_1 = open('hello.txt', 'r', encoding='utf-8')
for line in file_1:
    print(line)
file_1.close()
# Привет всем, добравшимся до 6-го урока.
#
# Работаем с файлами.
```

В этом примере файловый объект «превращается» в генератор (точнее, итератор) и в каждом шаге цикла возвращает очередную «сырую» строку текста (с управляющими символами).

Что можно улучшить в этом коде? Обернуть его в [менеджер контекста](#):

```
with open('hello.txt', 'r', encoding='utf-8') as file_1:
    for line in file_1:
        print(line)
```

Обратите внимание, что здесь мы **не вызываем** метод `.close()`. Это не ошибка. Именно в этом и есть смысл менеджера контекста — ответственность за освобождение ресурсов теперь на нём.

В будущем вы сможете писать свои менеджеры контекста. Основная идея следующая: можно задать действия при [входе](#) в данный контекст и действия при [выходе](#) из контекста.

Важно: использование менеджеров контекста ПРИВЕТСТВУЕТСЯ. Также зачастую режим `'r'` не указывают, он и так будет по умолчанию.

Запись файлов

От чтения перейдем к записи. Для текстовых файлов есть два метода [файлового объекта](#):

- `.write()` — сохраняет весь текст как одно целое;
- `.writelines()` — сохраняет список строк.

Попробуем первый:

```
txt = '''Попробуем записать в файл текст.
Используем метод .write().'''

with open('write_method.txt', 'w', encoding='utf-8') as f:
    f.write(txt)
```

В результате выполнения кода в папке урока должен появиться файл `write_method.txt`. Обратите внимание, что мы переименовали переменную файлового объекта в `"f"`. Вы часто будете видеть именно такое имя — это традиция. Вторая особенность примера: использовали тройные кавычки: так в Python можно записывать многострочные тексты в оригинальном виде, без символа `\`.

Теперь пример второго метода для записи данных в текстовый файл:

```
txt_lines = ['Пробуем записать в файл текст.',
             'Используем метод .writelines().']

with open('writelines_method.txt', 'w', encoding='utf-8') as f:
    f.writelines(txt_lines)
```

Разумеется, в результате выполнения этого кода получим файл `writelines_method.txt`. Но если мы его посмотрим, обнаружим, что все сохранилось в одну строку. Вы догадались, почему? На самом деле всё логично: если в Python мы читаем строки в «сыром» виде, то и писать их тоже нужно «сырыми» — без привнесения изменений в виде управляющих символов. Если поправим «исходники», всё станет хорошо:

```
txt_lines = ['Пробуем записать в файл текст.\n',
             'Используем метод .writelines().']

with open('writelines_method_upd.txt', 'w', encoding='utf-8') as f:
    f.writelines(txt_lines)
```

Какую ошибку часто допускают начинающие разработчики? Используют метод `.writelines()` для записи обычного текста. **Помните:** этому методу нужно передавать **список** в качестве аргумента!

ВАЖНО: во всех этих примерах всегда создается **НОВЫЙ** файл, если файл существовал — он уничтожается.

Если мы не хотим, чтобы уже существующие файлы перезаписывались, просто меняем режим доступа к файлу: вместо `'w'` будет `'x'`.

Изменение файлов: добавление и перезапись контента

В некоторых ситуациях нужно дописать данные в файл. Мы уже знаем про режим доступа `'a'`, но важно понимать ещё кое-что: открыть файл — это полдела. Вы же, когда редактируете текст, постоянно перемещаете **курсор** — Python тоже должен установить курсор (иногда его называют

«указатель») в нужную позицию перед добавлением данных. Если вы используете режим `'a'`, указатель будет установлен в конец открытого файла, а если режим `'r+'` — в начало. Проверим:

```
txt = '''Пробуем дозаписать в файл текст.  
Режим доступа "a"'''

with open('append_text.txt', 'a', encoding='utf-8') as f:  
    f.write(txt)
```

Вот что должно получиться после двукратного запуска скрипта:

append_text.txt

```
Пробуем дозаписать в файл текст.  
Режим доступа "a"Пробуем дозаписать в файл текст.  
Режим доступа "a"
```

Почему такой результат? Мы не перевели вторую строку в исходном тексте — вот и получили «сырую» склейку данных. Как поправить? Можно так:

```
txt = '''Пробуем дозаписать в файл текст.  
Режим доступа "a"  
'''
```

Теперь второй пример. Нужно создать пустой файл `replace_text_1.txt`. В режиме `'r+'` файл автоматически не создаётся! Выполним скрипт:

```
txt = '''Пробуем дозаписать в файл текст.  
Режим доступа "r+"  
'''

with open('replace_text_1.txt', 'r+', encoding='utf-8') as f:  
    f.write(txt)
```

Что-то меняется после нескольких запусков скрипта? Нет. Почему? Мы же каждый раз начинаем писать в файл с самого начала. При этом все символы перезаписываются новым текстом. Но новый текст совпадает со старым, поэтому ничего не меняется.

Ещё один эксперимент. Создаём пустой файл `replace_text_2.txt` и выполняем один раз скрипт:


```
txt = '''Пробуем дозаписать в файл текст.
Режим доступа "r+"
'''

with open('replace_text_2.txt', 'r+', encoding='utf-8') as f:
    f.write(txt)

txt = '''Пробуем ДОЗАПИСАТЬ в файл текст!
Режим ДОСТУПА
'''

with open('replace_text_2.txt', 'r+', encoding='utf-8') as f:
    f.write(txt)
```

В результате получаем текстовый файл:

replace_text_2.txt

```
Пробуем ДОЗАПИСАТЬ в файл текст!
Режим ДОСТУПА
r+"
```

Это результат записи второго текста поверх первого. Обратите внимание, что остаток первого текста сохранился — только появился ещё один перенос строки.

На самом деле подобные манипуляции в Python делаются редко, поэтому не нужно тратить много времени на этот раздел. Лучше более глубоко погрузиться в нюансы чтения и записи файлов.

* Перемещение курсора при работе с файлом: `.seek()` и `.tell()`

Можно ли в Python начать чтение с конкретной позиции курсора в файле? Давайте начнём с интроспекции. Создадим файл `hello_2.txt`:

```
Учимся читать файлы.
Можем установить указатель в нужную позицию.
Начало - 0.
Можно отсчитывать от конца файла.
```

И выполним скрипт:

```
with open('hello_2.txt', 'r', encoding='utf-8') as f:
    print(f.tell())
    line = f.readline()
    while line:
        print(line.strip(), f.tell(), sep='\n')
        line = f.readline()

# 0
# Учимся читать файлы.
# 39
# Можем установить указатель в нужную позицию.
# 123
# Начало - 0.
# 142
# Можно отсчитывать от конца файла.
# 203
```

Как вы уже догадались, [метод файлового объекта](#) `.tell()` возвращает текущую позицию указателя в файле. После чтения очередной строки, разумеется, позиция указателя увеличивается на длину этой строки. Часто возникает вопрос: в каких единицах эти числа? В [документации](#) для текстового режима сказано `opaque number` — некоторое условные числа, «попугаи». Почему так? Раз мы имеем дело с разными кодировками, длина кода символа может быть разной, и сделать одну единицу измерения не получится. Попробуйте написать текст на английском языке — получите числа, совпадающие с длиной строки плюс управляющие символы, ведь один символ для английского языка в UTF-8 — один байт. В нашем примере есть русские буквы — они по два байта, поэтому числа получились «труднообъяснимыми». Для файлов, открытых в **бинарном** режиме, метод `.tell()` даёт точное значение в байтах.

Примечание: использовали метод `.strip()` для очистки строки от управляющих символов в начале и конце.

Теперь попробуем поработать с методом файлового объекта `.seek()` — он перемещает указатель подобно тому, как мы это делаем курсорными клавишами при редактировании текста. Первым аргументом ему передаем смещение, а вторым — число, задающее начало отсчёта:

- 0 — от начала файла (по умолчанию);
- 1 — от текущей позиции;
- 2 — от конца файла.

Пример:

```
with open('hello_2.txt', 'r', encoding='utf-8') as f:
    f.seek(39)
    print(f.readline().strip())
    f.seek(142)
    print(f.readline().strip())
# Можем установить указатель в нужную позицию.
# Можно отсчитывать от конца файла.
```

Взяли числа из предыдущего примера и прочитали вторую и четвертую строки файла. В каких ситуациях может понадобиться метод `.seek()`? Например, мы итеративно обрабатываем очень большой текстовый файл — можем на каждой итерации запоминать положение указателя и при повторном запуске скрипта начинать не с начала, а с последней обработанной позиции. Следует отметить, что в реальном коде такие манипуляции выполняются нечасто.

Сериализация данных

Предположим, что мы работаем над серьёзным проектом, состоящим из нескольких логических модулей. Например, есть модуль, отвечающий за преобразование исходных данных в нужный формат. И есть другой модуль, где что-то с этими преобразованными данными делают — реализуют некоторую бизнес-логику. Как реализовать обмен данными между удалёнными частями системы? Один из вариантов решения — использовать файлы. Тут возникает вопрос: в каком виде хранить эти данные? Принципиально есть два способа: текстовый и бинарный.

Преимущество текстового формата — универсальность. Текстовые данные можно передавать практически любому адресату и любым способом, хоть в `url`-адресе — как, впрочем, и происходит в вебе (`GET`-запросы). Есть и недостаток: избыточность, особенно для чисел — получаем большой объём. Второй недостаток — нужно задавать или описывать способ хранения различных структур данных. Этот способ должны знать обе стороны: и отправитель, и получатель. Третий недостаток — трудности реализации хранения сложных структур, особенно с большой вложенностью. Но именно из-за универсальности и стабильности очень часто выбирают текстовый формат. Вам наверняка знакомы расширения `.csv`, `.xml`, `.json`, `.prn`. Ещё одним преимуществом является возможность «посмотреть» на данные в обычном текстовом редакторе.

В бинарном формате данные занимают намного меньше места, что позволяет быстрее их загрузить с диска. Так мы храним исполняемые файлы, медиа файлы, дампы данных и многое другое. Самым главным недостатком бинарного формата является меньшая универсальность — данные, которые вы сохранили в Python, не удастся прочитать в другом языке программирования.

Вернёмся к текстовому формату. Как, например, мы можем сохранить список? Если он содержит числа или строки, то вполне подойдёт результат вывода через функцию `print()`. То есть будем задавать границы через квадратные скобки, а элементы отделять запятой. Строки будем оборачивать в кавычки. То, что мы только что описали, называют [сериализацией](#) — превращением объекта в некоторый заданный формат (например, строковый) для последующей передачи или хранения. Это очень важная задача при разработке [web API](#). То есть вам надо решить, как вы будете преобразовывать объекты для передачи в виде строки в клиентскую часть: браузер или мобильное приложение. Обычно для этого пишут свои [сериализаторы](#). Но для большого круга задач достаточно встроенных в Python, например, из модуля [json](#).

Сериализация при помощи модуля `json`

Формат [JSON](#) можно считать «старожилом». Хотя он и был официально описан в 2006 году в [rfc4627](#), но упоминался еще в 2000-х. Изначально он задумывался для передачи объектов JavaScript, но вышел далеко за пределы этой задачи. Параллельно с ним зачастую упоминают формат [XML](#). Он похож на `html` — тоже используются теги, но более универсальный.

На самом деле для передачи данных при помощи текста (строк) необходима реализация двух процессов: сериализация (`encoder`) и десериализация (`decoder`) — обратное преобразование. В Python-модуле `json` получаем [следующее соответствие](#):

JSON	Python
object	dict
array	list
string	str
number (int)	int
number (real)	float
true	True
false	False
null	None

Попробуем преобразовать список:

```
import json
import random

nums = [random.randint(0, 100) for _ in range(10)]
```

```
nums_as_str = json.dumps(nums)
print(nums, type(nums))
print(nums_as_str, type(nums_as_str))
# [75, 97, 21, 90, 20, 60, 100, 96, 72, 39] <class 'list'>
# [75, 97, 21, 90, 20, 60, 100, 96, 72, 39] <class 'str'>
```

Использовали функцию [dumps\(\)](#), которая выполняет задачу сериализации Python-объектов в соответствии с приведенной выше таблицей. При выводе через функцию `print()` не видим никаких отличий, потому что типы данных [array](#) в JavaScript и `list` в Python похожи по синтаксису. Но есть и принципиальная разница: в первом случае объект имеет тип список, а во втором — строка. При попытке сохранить данные в текстовый файл это сразу проявится:

```
...
with open('nums.json', 'w', encoding='utf-8') as f:
    f.write(nums)
# ... TypeError: write() argument must be str, not list
```

Обычный список сохранить как текст не получилось.

```
...
with open('nums.json', 'w', encoding='utf-8') as f:
    f.write(nums_as_str)
# Process finished with exit code 0
```

А сериализованный список — получилось.

Попробуем теперь загрузить и десериализовать список:

```
import json

with open('nums.json', 'r', encoding='utf-8') as f:
    nums_as_str = f.read()
nums = json.loads(nums_as_str)
print(nums, type(nums))
# [38, 13, 26, 48, 36, 90, 24, 44, 15, 61] <class 'list'>
```

Всё получилось. Для десериализации использовали функцию [loads\(\)](#). Не всегда эти манипуляции проходят [гладко](#), но если вы получили [ошибку](#) сериализации, значит, уже добрались до серьезных задач и сможете найти решение.

Вы уже задумались о том, что можно сделать обёртку, которая будет выполнять сериализацию/десериализацию, а затем сохранение/загрузку файла? Если это так — отлично! Есть хорошие новости: такие обёртки существуют — это функции [dump\(\)](#) и [load\(\)](#). Коварство заключается в разнице в одну букву, поэтому очень часто начинающие разработчики получают ошибки при работе с модулем `json`. Перепишем пример заново:

```
import json
import random

nums = [random.randint(0, 100) for _ in range(10)]

with open('nums_again.json', 'w', encoding='utf-8') as f:
    json.dump(nums, f)

with open('nums_again.json', 'r', encoding='utf-8') as f:
    nums = json.load(f)
```

Разумеется, в реальной практике сохранение и загрузка будут выполняться в разные моменты времени и, скорее всего, в разных модулях. Здесь мы только хотели показать, насколько просто можно в Python решать простые задачи.

Рекомендуем внимательно ознакомиться с [официальной документацией](#) и понять назначение всех аргументов рассмотренных функций. Попробуйте самостоятельно сериализовать словари.

Работа с бинарными файлами. Модуль `pickle`

Как мы уже говорили, хранение данных в бинарном виде позволяет существенно уменьшить объём файлов и повысить скорость их загрузки. Зачастую мы даже не подозреваем, что работаем с бинарными файлами — обработка изображений и видео, документы Microsoft Office, анализ исполняемых файлов ОС, загрузка или сохранение из баз данных.

Рано или поздно вам понадобится сохранить в Python объект некоторого своего класса. Тут модуль `json` «из коробки» не поможет, нужно будет писать свой сериализатор. Во многих подобных случаях выручает модуль [pickle](#). В нем реализованы точно такие же функции, что и в модуле `json`: [dump\(\)](#), [dumps\(\)](#), [load\(\)](#), [loads\(\)](#). Разница только в необходимости дописывать `"b"` для режима доступа к файлу.

Проведём эксперимент для задачи: «В результате работы скрипта вычисляется список из одного миллиона вещественных чисел, который необходимо сохранить на диске и загрузить при его повторном запуске или для других скриптов в проекте — нужен своего рода файловый кеш». Решим задачу при помощи модулей `json` и `pickle`, при этом будем профилировать время:

```

import json
import pickle
import random
from time import perf_counter

nums = [random.random() * 10 ** 6 for _ in range(10 ** 6)]

start = perf_counter()
with open('random_million.json', 'w', encoding='utf-8') as f:
    json.dump(nums, f)
print(f'json saved: {perf_counter() - start}')

start = perf_counter()
with open('random_million.pickle', 'wb') as f:
    pickle.dump(nums, f)
print(f'pickle saved: {perf_counter() - start}')
# json saved: 4.176540619
# pickle saved: 0.14387575499999983

```

Как и предполагали, бинарный формат даёт очень серьёзное преимущество в скорости. Сравним размеры файлов:

- random_million.pickle — 8,58 МБ;
- random_million.json — 18,2 МБ.

С бинарным файлом получили более чем двукратное преимущество с точки зрения объёма на жестком диске. Теперь загрузим данные:

```

import json
import pickle
from time import perf_counter

start = perf_counter()
with open('random_million.json', 'r', encoding='utf-8') as f:
    nums = json.load(f)
print(f'json loaded: {perf_counter() - start}, {type(nums)}, {len(nums)}')

start = perf_counter()
with open('random_million.pickle', 'rb') as f:
    nums = pickle.load(f)
print(f'pickle loaded: {perf_counter() - start}, {type(nums)}, {len(nums)}')
# json loaded: 0.9602890079999999, <class 'list'>, 1000000
# pickle loaded: 0.2095523749999999, <class 'list'>, 1000000

```

Здесь бинарный формат снова вне конкуренции. Наверняка у вас возникает вопрос: зачем же тогда используют сериализацию в строку, если у бинарного формата такое существенное преимущество и в скорости, и в объёме? Плюс ещё можно сохранять объекты любых классов, не отвлекаясь на написание своих сериализаторов. Причины могут быть разные:

- **проблема совместимости разных языков программирования** — например, асинхронная передача данных от сервера, работающего на Python (Django, Flask), к фронтенду, работающему на JavaScript;
- **необходимость оперативного просмотра данных** — например, при отладке алгоритмов или анализе фрагментов лога можно json- или текстовые данные посмотреть в любом редакторе;
- **совместимость с будущими версиями приложения** — например, бинарные данные моделей, сохраненные в одной версии Django, могут не читаться в другой версии фреймворка.

*При работе с бинарными файлами можно читать данные порциями — количество считываемых байт передаётся как аргумент в метод `read()` файлового объекта:

```
import pickle

chunk_size = 256
with open('random_million.pickle', 'rb') as f:
    binary_data = bytearray()
    while True:
        chunk = f.read(chunk_size)
        if not chunk:
            break
        binary_data.extend(chunk)
    nums = pickle.loads(binary_data)
print(f'{type(nums)}, {len(nums)}')
# <class 'list'>, 1000000
```

Здесь читали данные порциями по 256 байт и добавляли в объект класса [bytearray](#) — массив байт, точнее, использовали метод `.extend()` этого объекта. По сути это типизированный список. Опять видим стройность в структуре языка Python. Наверняка у вас возник вопрос: есть ли аналогичный тип, но неизменяемый? Есть — это [bytes](#): по сути, типизированный кортеж. У класса `str` есть два метода для преобразования в последовательность байт и наоборот:

```
txt = 'Привет, Python!'
txt_binary = txt.encode(encoding='utf-8')
txt_origin = txt_binary.decode(encoding='utf-8')
print(txt_binary, type(txt_binary))
print(txt_origin, type(txt_origin))
# b'\xd0\x9f\xd1\x80\xd0\xb8\xd0\xb2\xd0\xb5\xd1\x82,Python!' <class 'bytes'>
# Привет, Python! <class 'str'>
```

Это дополнительный материал, поэтому вам придется самостоятельно изучить документацию по методам [.encode\(\)](#) и [.decode\(\)](#). Они часто используются в реальных проектах.

Практическое задание

1. Не используя библиотеки для парсинга, распарсить (получить определённые данные) файл логов web-сервера `nginx_logs.txt`

(https://github.com/elastic/examples/raw/master/Common%20Data%20Formats/nginx_logs/nginx_logs)

— получить список кортежей вида: (`<remote_addr>`, `<request_type>`, `<requested_resource>`). Например:

```
[
    ...
    ('141.138.90.60', 'GET', '/downloads/product_2'),
    ('141.138.90.60', 'GET', '/downloads/product_2'),
    ('173.255.199.22', 'GET', '/downloads/product_2'),
    ...
]
```

2. *(вместо 1) Найти IP адрес спамера и количество отправленных им запросов по данным файла логов из предыдущего задания.

Примечание: спамер — это клиент, отправивший больше всех запросов; код должен работать даже с файлами, размер которых превышает объем ОЗУ компьютера.

3. Есть два файла: в одном хранятся ФИО пользователей сайта, а в другом — данные об их хобби. Известно, что при хранении данных используется принцип: одна строка — один пользователь, разделитель между значениями — запятая. Написать код, загружающий данные из обоих файлов и формирующий из них словарь: ключи — ФИО, значения — данные о хобби. Сохранить словарь в файл. Проверить сохранённые данные. Если в файле, хранящем данные о хобби, меньше записей, чем в файле с ФИО, задаём в словаре значение `None`. Если наоборот — выходим из скрипта с кодом «1». При решении задачи считать, что объём данных в файлах во много раз меньше объёма ОЗУ.

Фрагмент файла с данными о пользователях (`users.csv`):

```
Иванов, Иван, Иванович
Петров, Петр, Петрович
```

Фрагмент файла с данными о хобби (`hobby.csv`):

```
скалолазание, охота
```

4. *(вместо 3) Решить задачу 3 для ситуации, когда объём данных в файлах превышает объём ОЗУ (разумеется, не нужно реально создавать такие большие файлы, это просто задел на будущее проекта). Только теперь не нужно создавать словарь с данными. Вместо этого нужно сохранить объединенные данные в новый файл (`users_hobby.txt`). Хобби пишем через двоеточие и пробел после ФИО:

Иванов,Иван,Иванович: скалолазание,охота

Петров,Петр,Петрович: горные лыжи

5. **(вместо 4) Решить задачу 4 и реализовать интерфейс командной строки, чтобы можно было задать имя обоих исходных файлов и имя выходного файла. Проверить работу скрипта.
6. Реализовать простую систему хранения данных о суммах продаж булочной. Должно быть два скрипта с интерфейсом командной строки: для записи данных и для вывода на экран записанных данных. При записи передавать из командной строки значение суммы продаж. Для чтения данных реализовать в командной строке следующую логику:
- просто запуск скрипта — выводить все записи;
 - запуск скрипта с одним параметром-числом — выводить все записи с номера, равного этому числу, до конца;
 - запуск скрипта с двумя числами — выводить записи, начиная с номера, равного первому числу, по номер, равный второму числу, включительно.

Подумать, как избежать чтения всего файла при реализации второго и третьего случаев.

Данные хранить в файле `bakery.csv` в кодировке `utf-8`. Нумерация записей начинается с 1.

Примеры запуска скриптов:

```
python add_sale.py 5978,5
python add_sale.py 8914,3
python add_sale.py 7879,1
python add_sale.py 1573,7
python show_sales.py
5978,5
8914,3
7879,1
1573,7
python show_sales.py 3
7879,1
1573,7
python show_sales.py 1 3
5978,5
8914,3
```

7. *(вместо 6) Добавить возможность редактирования данных при помощи отдельного скрипта: передаём ему номер записи и новое значение. При этом файл не должен читаться целиком — обязательное требование. Предусмотреть ситуацию, когда пользователь вводит номер записи, которой не существует.

Задачи со * предназначены для продвинутых учеников, которым мало сделать обычное задание.

Дополнительные материалы

1. [Лутц Марк. Изучаем Python.](#)
2. [Чтение и запись файлов в Python.](#)
3. [Модуль marshal для сериализации в Python.](#)
4. [Библиотека для сериализации marshmallow.](#)

Используемая литература

Для подготовки данного методического пособия были использованы следующие ресурсы:

1. <https://realpython.com/python-json/>.
2. <https://realpython.com/read-write-files-python/>.
3. <https://docs.python.org/3/>.